

Modul Informatik-II Kurs Informatik-3: Teil-5

www.engineering.zhaw.ch/de/engineering/studium/bachelor/informatik/studium-zurich.html

Prof. Dr. Olaf Stern
Leiter Studiengang Informatik
+41 58 934 82 51
olaf.stern@zhaw.ch

Lernziele: (Allgemein)



- Die Studierenden kennen die grundlegende Architektur von Rechnern und die wichtigsten Architekturelemente.
- Sie sind vertraut mit der elementaren Arbeitsweise eines Computers und der hardwarenahen Programmierung.
 Sie können diese an einfachen Beispiel erläutern.
- Die Studierenden kennen die grundsätzlichen Aufgaben eines Betriebssystems. Sie können die typischen Verfahren und Algorithmen, die bei der Entwicklung von Betriebssystemen zur Anwendung gelangen, beschreiben.

Lernziele: (Allgemein)



- Die Kurse der Module Informatik I und Informatik II (der Modulgruppen "Grundlagen der Informatik I+II") vermitteln den Studierenden die Grundlagen der Informatik, die jede / jeder Studierende unabhängig von der Wahl der Wahlpflichtmodule im Fachstudium erlangen sollte.
- Die vermittelten Grundlagen werden in den Modulen im Fachstudium vorausgesetzt.

Lernziele: Spezifisch Teil-5



- Die Studierenden kennen die Ziele für den Einsatz von Zwischenspeichern (Cache) und die Einordnung in der Speicherhierarchie eines Rechners; sie können insbesondere die Bedeutung eines Caches für die Leistung von Rechnern darlegen.
- Sie können den grundlegenden Aufbau und die Funktionsweise eines Cache (Lese- und Schreibvorgänge) erläutern und sind vertraut mit den verschiedenen elementaren Ansätzen direktabbildend und (satz-) assoziativ.
- Sie können an Beispielen den Einfluss der Parameter (Auslegung eines Cache) aufzeigen.

Lernziele: Spezifisch Teil-5



 Die Studierenden kennen den Aufbau und die Umsetzung eines virtuellen Speichers.

Themenüberblick Teil-5



Technische Informatik / Rechnerarchitektur

- Einführung / Übersicht
- Grundlegende Rechnerarchitektur
- Prozessoren
- Befehle die "Wörter" des Rechners
- "Mini-Power-PC"
- Speicher
 - Speicherarten und Speicheraufbau
 - Speicherhierarchie
 - Cache (Puffer, Zwischenspeicher)
- "Mini-Power-PC" (Fortsetzung)

Lerninhalte Teil-5



- Cache (Zwischenspeicher)
 - Einführung / Motivation
 - Lokalitätsprinzip
 - Grundlegende Definitionen
 - Lesezugriff
 - Assoziativer Cache
 - Direktabbildender Cache
 - Mischformen

Lerninhalte Teil-5



Cache (Zwischenspeicher)

– ...

Schreibzugriff

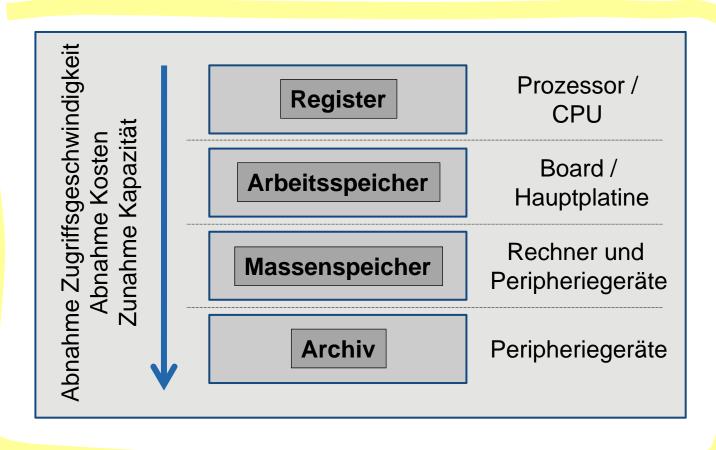
- Write Through
- Write Puffer
- Write Back

Optimierung und Multi-Level-Cache

- Virtuelle Speicher
 - > Aufbau
 - Umsetzung



Speicheraufbau – Speicherhierarchie



HS 2013/14

Olaf Stern, Studiengang Informatik (Standort Zürich), Modul Informatik-II, Kurs Informatik-3 Teil-5



Speicheraufbau – Speicherhierarchie

- Prozessoren (Rechen- / Steuerwerke) können Daten sehr schnell bearbeiten.
- Der Zugriff auf Daten im Arbeitsspeicher (heute DRAMs) ist dagegen langsam (unabhängig vom Von-Neumann-Flaschenhals).
- Nur wenige Daten können in den Registern vom(n) Rechen- und Steuerwerk(en) schnell bearbeitet werden.

Folge: Der Prozessor muss sehr häufig auf Daten warten!

Dieses wäre für sehr viele Anwendungen der Fall:

z. B. Bearbeitung von Texten, Matrizen, Audio, Video, Berechnung physikalischer oder chemischer Formeln, Näherungsverfahren, ...



Speicheraufbau – Speicherhierarchie

- Lösung für schnellen Zugriff auf viele Daten für den Prozessor (Rechen- und Steuerwerke)?
 - => Einen Zwischenspeicher, "*Puffer-Speicher*" auch "*Cache*" genannt, nutzen.

Prinzip:

Dem Nutzer (Rechner) "viel" kostengünstigen Speicher mit schnellen Zugriffszeiten (vergleichbar der schnellsten Speichertechnologie) zur Verfügung zu stellen.

[Der Begriff *Cache* wurde in den 60er-Jahren ursprünglich für den Pufferspeicher zwischen Prozessor und Arbeitsspeicher geprägt.]



Speicheraufbau – Speicherhierarchie

- Grundideen für einen Cache:
 - Der Zugriff auf Daten im Cache ist:
 - Zwar (ev.) langsamer als auf Daten direkt im Register
 - Aber erheblich schneller als auf Daten im Arbeitsspeicher.
 - Die Grösse / Kapazität eines Caches ist
 - Einerseits deutlich grösser als die der Register
 - Andererseits deutlich kleiner als der Arbeitsspeicher.

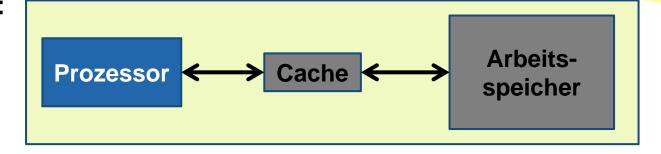
Dieser Ansatz lässt sich auf alle(n) Speicherebenen übertragen / nutzen!



Speicheraufbau – Speicherhierarchie

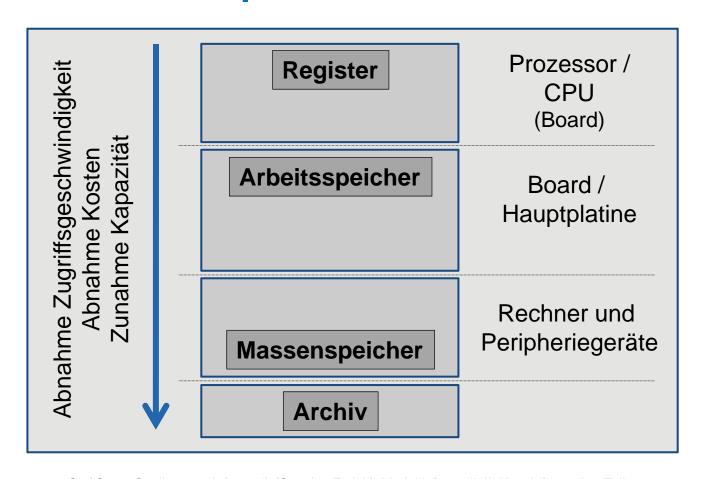
- Grundideen für einen Cache: (Forts.)
 - Statt auf den Arbeitsspeicher greift der Prozessor auf die Daten im Cache zu:
 - => Dafür müssen die Daten zuvor "nur" aus dem Arbeitsspeicher in den Cache kopiert worden sein.

– Grobschema:



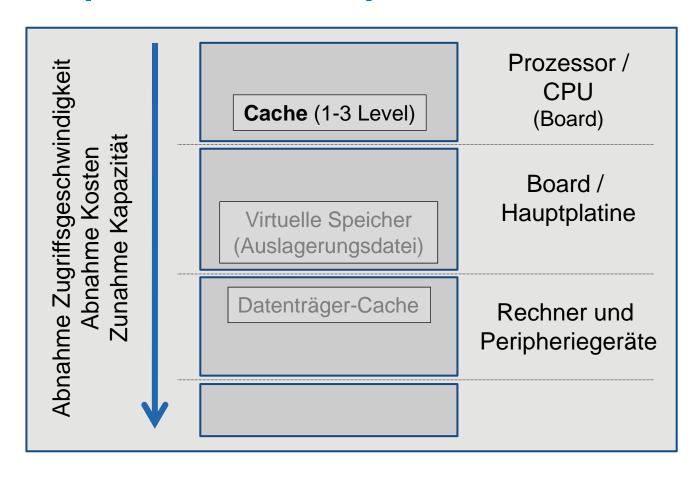


Speicheraufbau – Speicherhierarchie



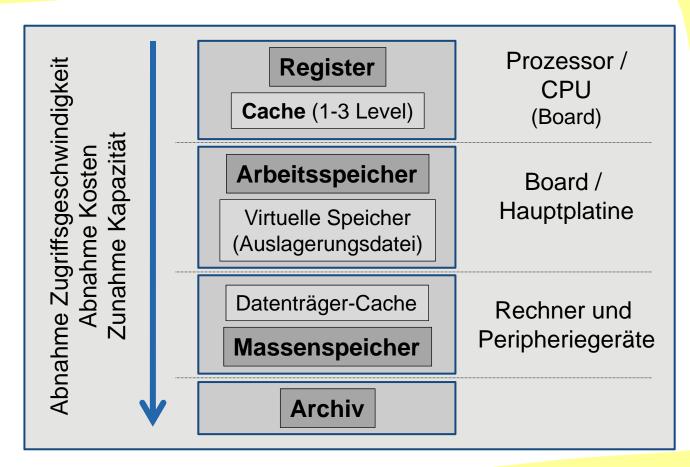


Zwischenspeicher in der Speicherhierarchie





Typische Speicherhierarchie eines Rechners





Speicheraufbau – verwendete Technologien

- Register: sehr schnelle Hardware, SRAM
- Cache: SRAM, Assoziativ-Speicher
- Arbeitsspeicher: DRAM (heute fast ausschliesslich)
- Auslagerungsdatei / Virtuelle Speicher: DRAM, Flash, schnelle Festplatten, Solid State Disk
- Datenträger-Cache: DRAM, SRAM (im Controller der Festpl.)
- Massenspeicher: Festplatten (magnetisch, optisch), Solid State
 Disk, Flash (USB-Stick), ...
- Archiv: Festplatten, CD, DVD, Solid State Disk, Flash (USB-Stick), (Magnet-)Bänder, Disketten, ...



Speicheraufbau – Speicherhierarchie

- Grundideen für einen Cache: (Forts.)
 - "... deutlich kleiner als der Arbeitsspeicher".
 (muss ja deutlich kleiner sein, sonst können die Kosten nicht reduziert werden!)
 - Zudem werden die Strukturen erheblich komplexer!
 (= zeitaufwendiger)
 - Mehr Bauteile
 - Daten müssen vom Register und Arbeitsspeicher zum Cache übertragen werden.
 - **>** ...



Speicheraufbau – Speicherhierarchie

- Grundideen für einen Cache: (Forts.)
 - "... deutlich kleiner als der Arbeitsspeicher".
 (muss ja deutlich kleiner sein, sonst können die Kosten nicht reduziert werden!)
 - Zudem werden die Strukturen erheblich komplexer !
 (= zeitaufwendiger)

Wieso funktioniert ein *Cache* erwiesenermassen dennoch sehr effizient?

Anmerkung: Konkret haben die Entwicklungen von *Caches* wesentlich zur **Steigerung** der **Rechenleistung** in den letzten Jahren beigetragen!



Speicheraufbau – Caches

Wieso funktioniert ein *Cache* erwiesenermassen dennoch sehr effizient?

- Lösung: Lokalität
 - a) Zeitliche Lokalität
 - Daten, die zuletzt genutzt wurden, werden mit grosser Wahrscheinlichkeit auch wieder in naher Zukunft genutzt
 - Bsp.: Befehle in Programmschleifen, Variablen, ...
 - b) Räumliche Lokalität
 - Mit sehr grosser Wahrscheinlichkeit wird nach dem Zugriff auf ein Datum in der Folge auf ein Datum zugegriffen, das in der "Nähe" abgespeichert ist.
 - Bsp.: Programmschleifen, Feld-Elemente, Textsuche, ...



Speicheraufbau – Caches

Wieso funktioniert ein *Cache* erwiesenermassen dennoch sehr effizient?

Lösung: Lokalität (zeitliche und räumliche)

Die Wahrscheinlichkeit ist sehr gross ist, ein Datum zu verwenden, dass

- bereits kürzlich verwendet wurde (zeitliche Lokalität)
- und/oder nahe zum bisherigen Datum abgespeichert ist (räumliche Lokalität)⁽⁺⁾

und daher bereits im Cache abgespeichert ist.

(+) Blockansatz => folgt



Caches

Definition:

"A safe place for hiding or storing things"

[Webster's New World Dictionary of the American Language, 3rd Edition, 1988]

"Cache bezeichnet in der EDV einen schnellen Puffer-Speicher, der Zugriffe auf ein langsames Hintergrundmedium oder zeitaufwendige Neuberechnungen nach Möglichkeit vermeidet.

- Meist werden hierzu Inhalte/Daten gepuffert, die bereits einmal verwendet und/oder berechnet wurden, um beim nächsten Zugriff schneller zur Verfügung zu stehen, oder/und
- vermutlich bald benötigte Daten vorab vom langsamen Hintergrundmedium geladen und bereitgestellt.

Caches sind als Puffer-Speicher realisiert, die Kopien zwischenspeichern. Sie können als Hardware- oder Softwarestruktur ausgebildet sein."

[http://de.wikipedia.org/wiki/Cache, Stand Aug. 2011]



Caches

- Grundbegriffe: [nach Patterson/Hennessy]
 - "Hit Rate" R_{hit} (Trefferrate):

Anteil der Speicherzugriffe auf einen Cache, die zu einem Treffer führen (Daten befinden sich im Cache).

- "Miss Rate" R_{miss} (Fehlzugriffsrate):

Anteil der Speicherzugriffe auf einen Cache, die nicht zu einem Treffer führen (Daten befinden sich nicht im Cache).

Es gilt: $R_{miss} = 1 - R_{hit}$



Caches

- Grundbegriffe: (Forts.)
 - "Hit Time" t_{hit} (Zugriffszeit bei Treffer):

Erforderliche Zeit für den erfolgreichen Zugriff auf ein Datum⁽⁺⁾ im Cache, inkl. der Zeit, die für den Test erforderlich ist, ob das Datum im Cache vorhanden ist.

- "Miss Penalty" t_{miss} (Fehlzugriffsaufwand):

Erforderliche Zeit für den Austausch eines Blocks⁽⁺⁾ im Cache aus der nächsten Ebene (z. B. dem Arbeitsspeicher), inkl. der Zeit, diesen Block Nutzer / Prozessor zur Verfügung zu stellen.

(+)Mit einem Datum wird im folgenden ein Wort assoziiert; Blockansatz => folgt



Caches

Grundbegriffe: Bedeutung

Da der *Fehlzugriffsaufwand* sehr hoch ist (Faktoren grösser als Zugriffszeit bei einem Treffer), reichen schon wenige Fehlzugriffe aus, um den Nutzen eines *Caches* deutlich zu reduzieren.

=> Es muss das primäre Ziel der Architektur eines Speichersystems mit Cache sein, die "Miss Rate" zu minimieren ...

... und die "Hit Time" zu optimieren; natürlich auch den Fehlzugriffsaufwand zu minimieren.

(Dieses gilt ebenso für das **Betriebssystem** und die **Compiler** / **Programme**)



Caches

- Grundbegriffe: Bedeutung Beispiel (vereinfacht)
 Beispieldaten für Prozessor ohne Cache:
 - Die **Zykluszeit** t_C für einen **Befehl** beträgt **1** Zeiteinheit (mit CPI = 1).
 - Der Zugriffszeit t_S für den Zugriff auf ein Datum direkt im Arbeitsspeicher beträgt 50 Zeiteinheiten.
 - Durchschnittlich 40% (Anteil A_s) aller Befehle eines Programms
 erfordern den Zugriff auf den Arbeitsspeicher (Lesen oder Schreiben).



Caches

Grundbegriffe: Bedeutung – Beispiel (vereinfacht)

Beispieldaten für Prozessor ohne Cache:

- ...

Beispieldaten für Prozessor mit Cache:

- Die Hit Time t_{hit} beträgt 2 Zeiteinheiten.
- Der Fehlzugriffsaufwand t_{miss} beträgt 100 Zeiteinheiten:
 - a) für **Test**, ob **Datum** im **Cache** steht,
 - b) um Datum im Arbeitsspeicher zu adressieren / anzusprechen und
 - c) um **Datum/Bock** in den **Cache** zu übertragen.
- Die Hit Rate R_{hit} beträgt a) 65% bzw. b) 98%.



Caches

Grundbegriffe: Bedeutung – Beispiel (vereinfacht)

Um wie viel % steigert der Cache die Rechenleistung?

Durchschnittliche Rechenzeit ohne Cache tohnec:

$$t_{ohneC} = (1 - A_S) * t_C + A_S * t_S$$

> Durchschnittliche Rechenzeit mit Cache t_{mitC}:

$$t_{mitC} = (1 - A_S) * t_C + A_S * (R_{hit} * t_{hit} + (1 - R_{hit}) * t_{miss})$$

> Steigerung der Rechenleistung: (t_{ohneC} / t_{mitC}) - 1

Anmerkung: Sehr vereinfachte Berechnung – u. a. keine Unterscheidung zwischen Leseund Schreibzugriffen.



Caches

Grundbegriffe: Bedeutung – Beispiel (vereinfacht)

Um wie viel % steigert der *Cache* die Rechenleistung?

 \triangleright Durchschnittliche Rechenzeit ohne Cache t_{ohneC} :

$$t_{ohneC} = 0.6 * 1 + 0.4 * 50 = 20.6$$
 [Zeiteinheiten]

 \triangleright Durchschnittliche Rechenzeit mit Cache t_{mitC} :

a)
$$t_{mitC-65} = 0.6 * 1 + 0.4 * (0.65 * 2 + 0.35 * 100) = 15.12$$
 [Zeiteinheiten] Steigerung der Leistung: $(t_{ohneC} / t_{mitC-65}) - 1 = (20.6 / 15.12) - 1 \approx 30\%$

b) $t_{mitC-98} = 0.6 \cdot 1 + 0.4 \cdot (0.98 \cdot 2 + 0.02 \cdot 100) = 2.184$ [Zeiteinheiten] Steigerung de Leistung: $(t_{ohneC} / t_{mitC-98}) - 1 = (20.6 / 2.184) - 1 \approx 845\%$



Caches

Beispiel – Schlussfolgerungen

- Mit einem gut entworfenen Cache kann die Rechenleistung eines Rechners deutlich gesteigert werden.
- Die Verbesserung der Leistungsfähigkeit des Caches bringt wesentlich mehr als die Steigerung der "reinen" Rechengeschwindigkeit eines Prozessors (wie z. B. die Erhöhung der Zyklusrate).
- Compiler und Programme, die das Prinzip der Lokalität unterstützen, können erheblich den Programmablauf beschleunigen.
- Ein "schlechter" Compiler / Programmierer kann jeden Prozessor "ausbremsen".



Caches – Realisierung / Umsetzung

Lesezugriffe – Grundansätze / Konzepte:

Allgemeine Vorgehensweise:

- 1) Der Prozessor fordert ein Datum an (über Adresse).
- 2) Das Datum wird im Cache gesucht.
 - a) Datum ist im Cache (und gültig):
 - Datum wird an den Prozessor zurückgegeben.
 - b) Datum ist nicht im Cache (oder ungültig):
 - Adresse wird an den Arbeitsspeicher gegeben.
 - Datum (bzw. Block) wird dort gelesen und in den Cache geschrieben.

mit 2a fortgesetzt



Caches – Realisierung / Umsetzung

Lesezugriffe – Grundansätze / Konzepte:

Da der *Cache* üblicherweise deutlich kleiner als der Hauptspeicher ist, können sich nicht alle Daten im *Cache* befinden:

- Woher weiss man nun, ob sich ein Datum im Cache befindet?
- Und wenn es sich im Cache befindet, wie finden wir es?

Grundansätze / Konzepte:

- a) Assoziativer Zugriff (voll)
- b) Direktabbildend
- c) Satzassoziativ (Satzorientiert)



Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - a) Assoziativer Zugriff Schema
 - Bei einem Assoziativspeicher wird die Adresse des gesuchten Datums mit allen Adressen der sich im Speicher befindenden Daten parallel verglichen

und

Falls eine Adresse übereinstimmt das Datum unmittelbar gelesen / geschrieben.

Dazu muss zu jedem Datum zusätzlich die Adresse abgespeichert werden (wird allgemein als Tag bezeichnet).



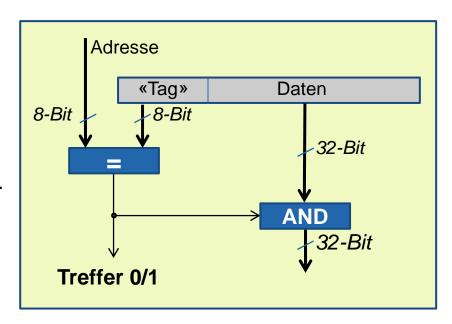
Caches – Realisierung / Umsetzung

Lesezugriffe – Grundansätze / Konzepte:

a) Assoziativer Zugriff – Grundprinzip (Bsp. Lesen)

Bsp. für einen *assoziativen* Speicher mit einem Adressbereich von *8* Bit (*2*⁸ Adressen) und einer Blockgrösse von *32* Bit.

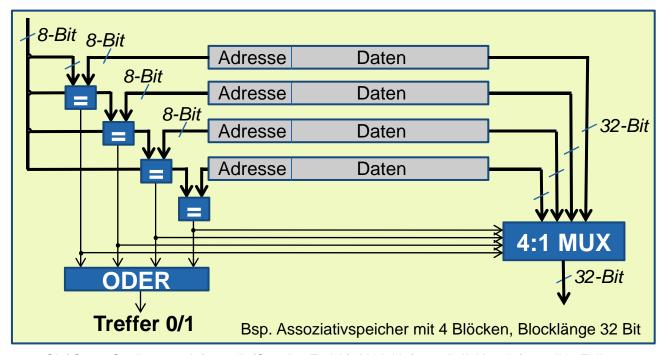
Über einen **Vergleicher** müssen die **8** Bit der Adressen vergleichen werden.





Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - a) Assoziativer Zugriff Grundprinzip (Bsp. Lesen)





Caches – Realisierung / Umsetzung

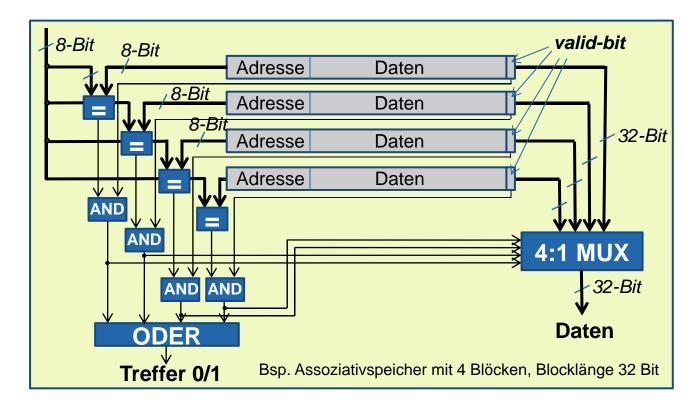
- Lesezugriffe Grundansätze / Konzepte:
 - a) Assoziativer Zugriff

Frage: Wie wird erkannt, ob ein Datum (Block) im *Cache* gültig (*valid*) ist?

=> Jeder Block beinhaltet ein zusätzliche Bit (valid bit), das angibt, ob die Daten gültig sind oder nicht.



- Lesezugriffe Grundansätze / Konzepte:
 - a) Assoziativer Zugriff Grundprinzip (Bsp. Lesen)





Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - b) *Direktabbildend* Schema:
 - Bei einem direktabbildenden Speicher wird jeder Adresse im Speicher genau eine Adresse (Position) im Cache zugeordnet.

Die **Abbildung** ist **sehr einfach** – in der Regel über die "**modulo**"-**Funktion** realisiert:

Cache-Adresse = (Block-Adresse) modulo (Anzahl Blöcke im Cache)

(Grösse von **Speicher** und **Cache** sind i. d. R. ein **Vielfaches** von **2**.)



Caches – Realisierung / Umsetzung

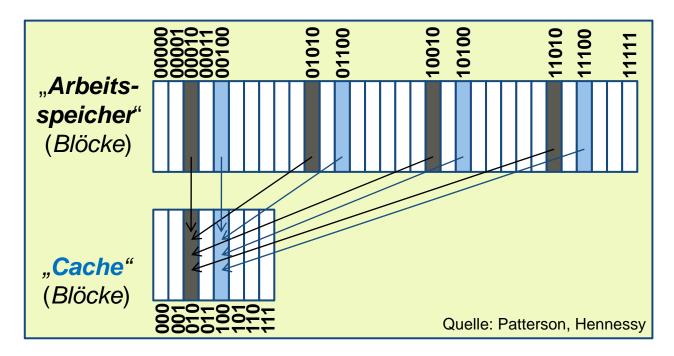
- Lesezugriffe Grundansätze / Konzepte:
 - b) Direktabbildend Grundprinzip (Bsp. Abbildung)
 - Arbeitsspeicher mit 32 Blöcken
 - Cache mit 8 Blöcken
 - Block z. B. 4 Byte

Die **Blockgrösse** ist i. d. R. ein **Vielfaches** der **Wortgrösse**:

Blockgrösse = Wortgrösse * 2^m , $m \in IN$



- Lesezugriffe Grundansätze / Konzepte:
 - b) Direktabbildend Grundprinzip (Bsp. Abbildung)





Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - b) Direktabbildend Grundprinzip (Bsp. Abbildung)

Der Block im Arbeitsspeicher mit der Adresse 00010 wird auf den Block im Cache mit der Adresse 010 abgebildet, ebenso die Blöcke 01010, 10010 und 11010.

- Um zu erkennen, ob ein Block im Cache den gesuchten Daten entspricht, wird wiederum ein zusätzlicher "Tag" mit abgespeichert, der einen Teil der Blockadresse beinhaltet (im Bsp. die Bits 0 und 1 der Blockadresse), und beim Test abgeglichen.
- Die vollständige Blockadresse ist nicht notwendig, da diese partiell im Index schon enthalten ist (im Bsp. die Bits 2, 3 und 4 der Blockadresse).



Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - b) Direktabbildend Grundprinzip (Bsp. Abbildung)

Cache mit Tags (des Beispiels):

- Gesucht der Eintrag für die Block-Adresse: "0 10 1 15

Beispiel für eine Belegung im *Cache*

Index	Tag	Datenblöcke	
000	0 0	"Daten: 32 Bit"	
0 0 1	0 1	"Daten: 32 Bit"	
010	11	"Daten: 32 Bit"	
011	0 1	"Daten: 32 Bit"	
100	0 1	"Daten: 32 Bit"	
101	1 1	"Daten: 32 Bit"	
110	1 1	"Daten: 32 Bit"	
111	0 0	"Daten: 32 Bit"	

Index



Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - b) Direktabbildend Grundprinzip (Bsp. Abbildung)

Cache mit Tags (des Beispiels):

Gesucht der Eintrag für die Block-Adresse: "0 1



Beispiel für eine Belegung im *Cache*

Berechnung vom Index:

 $01011_2 \ \text{modulo} \ 1000_2 = 011_2$

Index	Tag	Datenblöcke	
000	0 0	"Daten: 32 Bit"	
001	0 1	"Daten: 32 Bit"	
010	11	Daten: 32 Bit"	
011	0 1	"Daten: 32 Bit"	
100	0 1	"Daten: 32 Bit"	
101	1 1	"Daten: 32 Bit"	
110	11	"Daten: 32 Bit"	
111	0 0	"Daten: 32 Bit"	



Caches - Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - b) Direktabbildend Beispiel Adressberechnung

Gegeben sei ein Cache mit 32 Blöcken von je 4 Bytes

Auf welchen Block (Tag) im Cache wird das Byte im Arbeitsspeicher mit der Adresse 2410 abgebildet? (Beginn bei Adr. 0)

Blockadresse = $\lfloor Byteadresse / (Bytes pro Block) \rfloor$ Blockadresse = $\lfloor (2410+1) / 4 \rfloor = \lfloor 602.75 \rfloor = 602$

Cache-Blocknummer (Tag) = (Blockadresse) modulo (Anzahl Blöcke im Cache)

Cache-Blocknummer (Tag) = 602 modulo 32 = 26 (es ist dort das 4. Byte; 2407 ist das 1. Byte)



Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - b) Direktabbildend Beispiel Grössenberechnung

Gegeben sei für einen Arbeitsspeicher mit 2³² Byte ein direktabbildender Cache mit 4 KiB Daten⁽⁺⁾, einer Blockgrösse von 4 Wörtern und einer Wortlänge von 32 Bit (4 Byte).

Wie gross ist die tatsächliche Anzahl von Bits für den Cache?

(+)Zur Erinnerung: 4 KiB bedeuten exakt 2¹² = 4096 Byte, leider wird umgangssprachlich auch häufig 4 KB gesagt.



Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - b) Direktabbildend Beispiel Grössenberechnung
 - Wie gross ist die tatsächliche Anzahl von Bits für den Cache?
 - => Blockanzahl * (Blockgrösse + Tag-Grösse + Flag-Bits)
 - Blockgrösse: 4 * 4 Byte = 2⁴ Byte = 16 Byte (= 2⁷ Bit)
 - *Blockanzahl* (= Nr. Indexe): 2¹² / 2⁴ Byte = **2**⁸ Byte = **256** Blöcke
 - Wörter pro Block: 4 Byte = 2² Byte
 - Byte pro Wort: 4 Byte = 2² Byte
 => Grösse Tag-Feld: 32 8 2 2 Bit = 20 Bit
 - Valid-Bit pro Block: 1 Bit
 - \Rightarrow ca. $2^{8} \cdot (2^{7} + 20 + 1)$ Bit = 38'144 Bit = 4'768 Byte

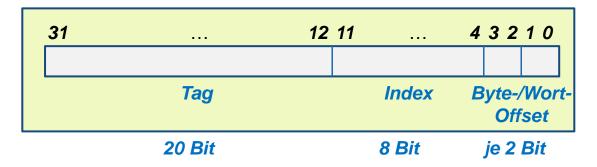
(Vereinfacht - in der Praxis zuzüglich weiterer *Flags / Zähler*)



Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - b) Direktabbildend Beispiel Grössenberechnung
 - Wie gross ist die tatsächliche Anzahl von Bits für den Cache?

Blockgrösse: "Aufteilung der Adresse": (für das vorherige Beispiel)

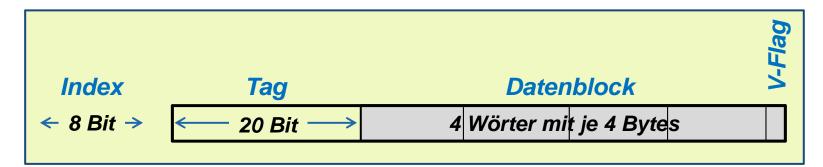




Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - b) Direktabbildend Beispiel Grössenberechnung
 - Wie gross ist die tatsächliche Anzahl von Bits für den Cache?

Aufbau eines Datenblocks: (für das vorherige Beispiel)





Caches – Realisierung / Umsetzung

Lesezugriffe – Grundansätze / Konzepte:

a) + b) Vergleich: Assoziativ \Leftrightarrow Direktabbildend

Cachestruktur	assoziativ	direktabbildend
Zugriffszeit (bei Treffer)	höher	geringer
Trefferrate (im Durchschnitt)	höher	geringer
Komplexität = Kosten	gross	geringer



- Lesezugriffe Grundansätze / Konzepte:
 - c) Satzassoziativ
 - Ist eine Mischform von einem direktabbildenden Cache und einem assoziativen Cache.
 - Ein Block kann statt auf genau einem Platz, wie bei einem direktabbildenden Cache, auf eine vorgegebene Anzahl von Positionen (i. d. R. Vielfaches von 2, wird als Satz bezeichnet) beliebig abgelegt werden.
 - Suche in einem satzassoziativen Cache:
 - Ein Block wird direkt auf einen Satz abgebildet und
 - innerhalb der Positionen eines Satzes assoziativ gesucht.



- Lesezugriffe Grundansätze / Konzepte:
 - c) Satzassoziativ: Beispiel
 - 2 Positionen (2-fach satzassoziativer Cache)
 - 4 Sätze (zu Blöcken von je 32 Bit)

Satz- Index	Tag	Datenblöcke	v-Bit
niacx 0	0 0	"Daten: 32 Bit"	
U	0 1	"Daten: 32 Bit"	
4	11	"Daten: 32 Bit"	
ı	0 1	"Daten: 32 Bit"	
2	0 1	"Daten: 32 Bit"	
	11	"Daten: 32 Bit"	
3	11	"Daten: 32 Bit"	
, s	0 0	"Daten: 32 Bit"	



- Lesezugriffe Grundansätze / Konzepte:
 - c) Satzassoziativ
 - Typische Satzgrösse: 2 oder 4 Positionen
 (2- bzw. 4-fach satzassoziativer Cache)
 - => Mehrkosten bzgl. Zeit und zusätzlicher Hardware vertretbar ...



Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - c) Satzassoziativ
 - Typische Satzgrösse: 2 oder 4 Positionen
 (2- bzw. 4-fach satzassoziativer Cache)
 - ... und heuristisch wurde gezeigt, dass eine grössere Assoziativität ev. nur noch wenig bringt!

Quelle (Daten): Hennessy / Patterson [2003]

n-fach satzassoziativ	Datenfehl- zugriffsrate	Verbesserung (abs. / rel.)
1	10.3 %	-
2	8.6 %	16.5 % (-)
4	8.3 %	19.4 % (3.5 %)
8	8.1 %	21.4 % (2.5 %)



- Lesezugriffe Grundansätze / Konzepte:
 - c) Satzassoziativ
 - Mehrkosten für n-fach satzassoziativen Cache entstehen insb. durch die erforderlichen Vergleicher (Chip-Fläche für Hardware) und längere Laufzeiten, da der kritische Pfad grösser wird.
 - Mit neuen CAM (Content Addressable Memory) auch teilweise
 8/16-fach satzassoziativer Cache implementiert.



- Lesezugriffe Grundansätze / Konzepte:
 - c) Satzassoziativ
 - Ein 1-fach satzassoziativer Cache ist ein Sonderfall und entspricht einem Cache mit direktem Zugriff.
 - Ein *n-fach satzassoziativer Cache* bei einem *Cache* mit insgesamt *n* Blöcken ist ebenfalls ein Sonderfall und entspricht einem *Cache* mit *voll-assoziativem* Zugriff.



- Lesezugriffe Grundansätze / Konzepte:
 - b) + c) Verdrängung bei assoziativ und satzassoziativ
 - Wenn alle Blöcke in einem assoziativen Cache (alle Blöcke in einem Satz) belegt sind, muss, wenn ein neues Datum in den Cache aufgenommen werden soll, ein bestehender Eintrag (Blockeintrag) "verdrängt" (d. h. überschrieben) werden.
 - => Dafür gibt es grundsätzliche drei Ansätze:
 - Least recently used (LRU)
 - Least frequently used (LFU)
 - First in first out (FIFO)



Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - b) + c) Verdrängung bei *assoziativ* und *satzassoziativ*
 - Least Recently Used (LRU):

Es wird der Block entfernt (überschrieben), dessen Zugriff am längsten zurückliegt.

Realisierung: z. B. über einen Zugriffszähler

Least Frequently Used (LFU)

Es wird der Block entfernt (überschrieben), auf den am wenigsten häufig zugegriffen wurde.

Realisierung: ebenfalls z. B. über einen Zugriffszähler



Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - b) + c) Verdrängung bei *assoziativ* und *satzassoziativ*
 - First In First Out (FIFO):

Es wird der **Block entfernt** (überschrieben), der zeitlich am **längsten** im **Cache** liegt.

Realisierung: z. B. einfach über ein Flag

- Weitere: Random, Climb, Clock, ...

Auch wenn *FIFO* **nicht so hohe Trefferraten** wie die anderen Ansätze erreicht, wird dieser Ansatz dennoch **sehr häufig genutzt**.

=> Der Grund ist die einfache Realisierung!



Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - c) Satzassoziativ Beispiel Grössenberechnung

Gegeben sei für einen Arbeitsspeicher mit 2³² Byte ein 4-fach satzassoziativer Cache mit 4 KiB Daten, einer Blockgrösse von 4 Wörtern, einer Wortlänge von 32 Bit und FIFO als Verdrängungsmethode (= 1 zusätzliches Bit pro Block).

- Wie gross ist die tatsächliche Anzahl von Bits für den Cache?
 - => Satzanzahl * (Satzgrösse + Tag-Grösse + Flag-Bits)



Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - c) Satzassoziativ Beispiel Grössenberechnung
 - Wie gross ist die tatsächliche Anzahl von Bits für den Cache? (Näherungsweise)
 - Blockgrösse: 4 * 32 Bit = 2⁷ Bit = 128 Bit (= 2⁴ Byte)
 - Satzgrösse: 4 * 4 * 32 Bit = 29 Bit = 512 Bit (= 26 Byte)
 - (Blockanzahl: 2^{12} Byte $/ 2^4$ Byte = $2^8 = 256$ Blöcke)
 - **Satzanzahl**: 2^{12} Byte $/ 2^{6}$ Byte = 2^{6} = 64 **Sätze**
 - Wörter pro Block: 4 Byte = 2² Byte
 - Byte pro Wort: *4 Byte* = **2**² **Byte**

=> Tag-Feld: 32 - 6 - 2 - 2 Bit = 22 Bit



Caches – Realisierung / Umsetzung

- Lesezugriffe Grundansätze / Konzepte:
 - c) Satzassoziativ Beispiel Grössenberechnung
 - Wie gross ist die tatsächliche Anzahl von Bits für den Cache? (Näherungsweise)
 - Valid-Bit pro Block: 1 Bit
 - Flag für FIFO-Realisierung pro Block: 1 Bit
 - => Satzanzahl * (Satzgrösse + Tag-Grösse + 1 + 1)= $2^8 * (2^7 + 22 + 1 + 1) Bit = 38'912 Bit = ca. 4'864 Byte$

(Vereinfacht - in der Praxis zuzüglich weiterer *Flags*)

[Zur Erinnerung: Die eigentliche Mehrfläche wird durch die notwendige zusätzliche Logik (Vergleicher) verursacht.]



Caches – Realisierung / Umsetzung

Lesezugriffe – Optimierung:

- "Early-Restart"

Ziel: Reduktion des Fehlzugriffsaufwands

- Nach einem Fehlzugriff wird die Programmausführung bereits fortgesetzt, sobald das angeforderte Wort des Blocks geladen wurde (statt auf das Laden des ganzen Blocks zu warten); die folgenden Wörter werden dann "just in time" geliefert.
- Funktioniert bei **Zugriffen** auf **Befehle** und **grosser Blockgrösse recht gut**, **weniger gut** allgemein für **Datenzugriffe** (Zugriffe auf Befehle erfolgen häufig **sequentiell**).



Caches – Realisierung / Umsetzung

- Lesezugriffe Optimierung:
 - "Requested Word First" bzw. "Critical Word First"

Ziel: Reduktion des Fehlzugriffsaufwands

- Komplexer als Early-Restart insofern, dass zusätzlich zum Ansatz von Early-Restart nach einem Fehlzugriff das angeforderte Wort zuerst geladen wird und anschliessend erst die restlichen Wörter des Blocks.
- > Schneller als *Early-Restart*, wenn das angeforderte Wort erst später im Block auftritt.
- Dafür aufwendiger zu implementieren (zusätzliche Logik und Speicherorganisation).



- Schreibzugriffe Grundansätze / Konzepte:
 - Schreibzugriffe sind grundsätzlich komplexer als Lesezugriffe!
 - Wenn nach einem Schreibzugriff auf Daten diese nur in den Cache geschrieben werden, enthalten Speicher und Cache unterschiedliche Daten.
 - => Cache und Speicher sind inkonsistent.



Caches – Realisierung / Umsetzung

- Schreibzugriffe Grundansätze / Konzepte:
 - Einfachste Bearbeitung von Schreibzugriffen:
 - "Write-Through" (Durchschreibetechnik)
 - Bei jedem Schreibvorgang werden die Daten sowohl in den Cache als auch in den Speicher geschrieben.
 - => Cache und Speicher sind immer konsistent!
 - Sehr einfach zu realisieren, jedoch sehr schlechte Performance, da bei jedem Schreibzugang auf den Arbeitsspeicher zugegriffen werden muss!

[Bei einem Fehlzugriff wird zuerst der Block aus dem Speicher in den Cache geladen und anschliessend sowohl in den Cache wie auch in den Speicher - 65 geschrieben.]



Caches – Realisierung / Umsetzung

- Schreibzugriffe Grundansätze / Konzepte:
 - Effizientere Bearbeitung von Schreibzugriffen:

Verwendung von "Write Puffer" (Schreibpuffer)

- Bei einem Schreibvorgang werden die Daten in den Cache und einen in Schreibpuffer geschrieben und das Programm dann bereits fortgesetzt.
- Aus dem Schreibpuffer werden die Daten dann im Hintergrund in den Speicher geschrieben und anschliessend der Eintrag aus dem Schreibpuffer entfernt.

- ...



Caches – Realisierung / Umsetzung

- Schreibzugriffe Grundansätze / Konzepte:
 - Effizientere Bearbeitung von Schreibzugriffen:

Verwendung von "*Write Puffer*" (*Schreibpuffer*) – Forts.

- Das Schreiben in den Schreibpuffer erfolgt deutlich schneller als in den Speicher.
- Grösse des Schreibpuffers ist für Performance wichtig.
- Bei sehr vielen unmittelbar aufeinanderfolgenden Schreibzugriffen ("bursts") kann der Schreibpuffer diese nicht mehr aufnehmen und muss "warten".
- [Konflikte mit "DMA"-Zugriffen müssen berücksichtigt werden.]



- Schreibzugriffe Grundansätze / Konzepte:
 - Weiterer Ansatz: "Write Back" (Rückschreibetechnik)
 - Bei einem Schreibvorgang werden die Daten nur in den Cache geschrieben und das Programm dann bereits fortgesetzt und der Block mit einem Flag, "dirty bit", markiert.
 - Erst wenn der Block im Cache überschrieben wird, erfolgt (unmittelbar zuvor) das Schreiben in den Speicher (ev. mit Schreibpuffer).



Caches – Realisierung / Umsetzung

- Schreibzugriffe Grundansätze / Konzepte:
 - Weitere Unterscheidung:
 - Write Allocation und
 - No Write Allocation

Wenn es bei einem Schreibvorgang zu einem Fehlzugriff kommt, wird direkt in den Speicher geschrieben, nicht aber in den Cache.

Hintergrund ist

- Die bessere Performance (und die einfachere Handhabung), wenn ganze Seiten im Speicher ausgetauscht werden.
- Im Cache werden keine anderen, ev. wichtigeren Einträge verdrängt.



Caches – Realisierung / Umsetzung

- Anmerkungen und allgemeine Optimierungen
 - Kombination der verschiedenen Ansätze für Lese- und Schreibzugriffe
 - Unterschiedliche Handhabung (insb.) der Schreibzugriffe

ACHTUNG: DMA-Zugriffe müssen mit einbezogen bzw. berücksichtigt werden.

DMA (**Direct Memory Access**) gestattet **Peripheriegeräten** den **direkten Zugriff** auf **Daten** im **Speicher**, ohne dass der **Prozessor damit belastet wird**, z. B. Kopie von **Daten** im **Speicher** auf eine **CD**.



Caches – Realisierung / Umsetzung

- Anmerkungen und allgemeine Optimierungen
 - Beobachtung zur Blockgrösse:

Fehlzugriffsrate sinkt zunächst bei grösseren Blöcken,

=> räumliche Lokalität wird besser genutzt

steigt aber bei zu grossen Blöcken wieder an, weil

- => bei sehr grossen Blöcken (bei gleichgrossem *Cache*) die Anzahl der Blöcke abnimmt und ein Block häufiger im *Cache* verdrängt wird,
- => eventuell überhaupt nicht auf alle Wörter eines Blocks zugegriffen wird (zuvor schon wieder verdrängt).

Zudem steigt der Fehlzugriffsaufwand mit der Blockgrösse.



- Anmerkungen und allgemeine Optimierungen
 - Getrennte Caches für Befehle und Daten:
 - Unterschiedliche Ansätze für Optimierung der Lese- und Schreibzugriffe einfach realisierbar.
 - Unterschiedliche Wortbreite (z. B. Cache für Befehle kleiner) und Kapazitäten / Grössen.
 - Positiver Nebeneffekt: Erhöhung der Bandbreite
 - > Cachekapazität muss aufgeteilt werden.
 - => Führt zu geringfügig erhöhten Trefferraten.



Caches – Realisierung / Umsetzung

- Anmerkungen und allgemeine Optimierungen
 - Mehrstufige Caches (heute häufig zweistufig realisiert):
 - Ein kleiner, sehr schneller Cache; direkt im Prozessorkern implementiert (einfache Realisierung).
 - => Optimierung der *Hit Time*
 - [Arbeiten i. d. R. synchron (1:1) zur Prozessorgeschwindigkeit, so dass bei einem Treffer überhaupt nicht gewartet werden muss.]
 - Ein grösserer etwas langsamerer zweiter Cache auf dem Mainboard, der häufig deutlich komplexer ist.
 - => Optimierung des *Fehlzugriffsaufwandes*



Caches – Realisierung / Umsetzung

- Beispiel für Cache-Leistung (a)
 - Prozessor mit 4 GHz (entspricht 0.25 ns Zykluszeit)
 - CPI = 1 für Befehle, die nicht auf den Speicher zugreifen (im \emptyset), CPI = 50 für Speicherbefehle (Load / Store) (= $50 \cdot 0.25 \text{ ns} = 12.5 \text{ ns}$).
 - Bei ca. 40 % der Befehle wird auf den Speicher zugegriffen (im ∅).
 - "On-Chip"-Cache:
 - > 2-fach satzassoziativ (sehr schnell, aber teuer)
 - Hit-Rate von 96% (statistisch ermittelt)
 - Hit-Time von einem Taktzyklus
 - **Fehlzugriffsaufwand: 100 Zyklen** (= 100 ∗ 0.25 ns = 25 ns)



Caches - Realisierung / Umsetzung

Beispiel für Cache-Leistung (a) (Forts.)

Wie lange dauert die Bearbeitung eines Befehls im Durchschnitt?

- Ohne Cache:
$$t_{ohneC} = (1 - A_S) * T_C + A_S * T_S$$

= $(0.6 * 0.25 ns + 0.4 * 12.5 ns) = 5.15 ns$

- Mit Cache:
$$t_{mitC} = (1 - A_S) * T_C + A_S * (R_{hit} * t_{hit} + (1 - R_{hit}) * t_{miss})$$

= $0.6 * 0.25 \text{ ns} + 0.4 * (0.96 * 0.25 \text{ ns} + 0.04 * 25 \text{ ns})$
= 0.646 ns

=> Leistungssteigerung durch den Cache: (5.15 / 0.646) -1 ≈ 800%



Caches – Realisierung / Umsetzung

- Beispiel für Cache-Leistung (b)
 - Derselbe Prozessor wird nun mit bei identischen Gesamtkosten mit zwei Caches ausgestattet (fiktives Beispiel):
 - Level-1-Cache ("On-Chip"): Direktabbildend (klein, schnell)
 - Hit-Rate von "nur" noch 92% (statistisch ermittelt); u. a. da kleiner
 - Hit-Time von einem Taktzyklus
 - > Level-2-Cache ("On-Board"): 4-fach satzassoziativ (gross, langs.)
 - Hit-Rate von 80% (statistisch ermittelt) für die Fehlzugriffe des Level-1-Cache
 - Hit-Time von 6 Taktzyklen (=6 * 0.25 ns = 1.5 ns)
 - Fehlzugriffsaufwand von 100 Zyklen (= 100 * 0.25 ns = 25 ns)



Caches – Realisierung / Umsetzung

Beispiel für Cache-Leistung (b) (Forts.)

Wie lange dauert die Bearbeitung eines Befehls im Durchschnitt?

- Mit Cache_{2-Level}:
$$t_{mitC2} = (1 - A_S) * T_C + A_S * (R_{hit-C1} * t_{hit-C1} + (1 - R_{hit-C1}))$$

$$* (R_{hit-C2} * t_{hit-C2} + (1 - R_{hit-C2}) * t_{miss-C2}))$$

$$= 0.6 * 0.25 \text{ ns} + 0.4 * (0.92 * 0.25 \text{ ns} + 0.08 *$$

$$(0.8 * 1.5 \text{ ns} + 0.2 * 25 \text{ ns}))$$

$$= 0.4404 \text{ ns}$$

Leistungssteigerung gegenüber 1-stufigem *Cache*:

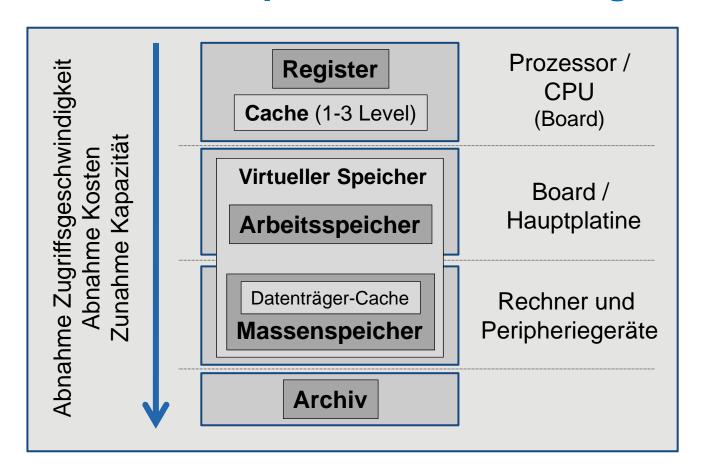
$$(0.646 \text{ ns} / 0.4404 \text{ ns}) - 1 \cong 47\%$$

[bzw. (5.15 ns / 0.4404 ns) -1 ≈ 1170% gegenüber keinem Cache]

HS 2013/14



Caches – Virtueller Speicher: Einordnung





- Analog der Funktion eines Caches für den Arbeitsspeicher kann der Arbeitsspeicher als "Cache" für den Massenspeicher dienen!
- Wesentlicher Unterschied:
 - Dieser "Cache" wird primär durch den Arbeitsspeicher selber,
 Software und wenig zusätzlicher Hardware realisiert es gibt keinen physikalischen Cache.



Caches - Virtueller Speicher

Analog der Funktion eines Caches für den Arbeitsspeicher kann der Arbeitsspeicher als "Cache" für den Massenspeicher dienen!

Wesentlicher Unterschied:

- Dieser "Cache" wird primär durch den Arbeitsspeicher selber,
 Software und wenig zusätzlicher Hardware realisiert es gibt keinen physikalischen Cache.
- Die Entwicklung wurde neben dem Ziel eines schnelleren
 Zugriffs auch durch "weitere Aufgaben / Funktionen" ausgelöst und vorangetrieben.



Caches – Virtueller Speicher

- Weiteren Aufgaben / Funktionen:
 - Die gemeinsame sichere Nutzung des Speichers durch viele Programme (gleichzeitig).

Auf einem Rechner sind immer mehrere Programme (Prozesse) gleichzeitig aktiv: Jedes Programm darf nur den Teil des Speicher lesen und insbesondere verändern, der ihm zugeordnet ist.



Caches – Virtueller Speicher

- Weiteren Aufgaben / Funktionen: (Forts.)
 - Die Vergrösserung des physikalischen Speichers
 - a) Für ein Programm:

Ein **Programm** kann für seine **Ausführung mehr Speicherplatz** erfordern, als **physiklisch zur Verfügung steht** – dieses war in der Vergangenheit häufig der Fall und musste durch den Programmentwickler mühsam durch die "**overlay**"-Technik umgangen werden.



Caches - Virtueller Speicher

- Weiteren Aufgaben / Funktionen: (Forts.)
 - Die Vergrösserung des physikalischen Speichers
 - b) Für mehrere Programme:

Der erforderliche Speicher für viele hundert oder gar tausend Programme ist schnell grösser als der tatsächlich vorhandene physikalische Arbeitsspeicher.

Sie gaben dem Ansatz / der Technik auch den heute üblicherweise verwendeten Begriff: "virtueller Speicher" ...

... auch wenn die Grundansätze und -methoden identisch mit denen für einen Cache für den Arbeitsspeicher sind!



- "Bezeichnungen"
 - Statt "Cache" heisst es "virtueller Speicher"
 - Ein virtueller Speicherblock wird "Seite" (engl. "page") genannt.
 - Ein Speicherfehlzugriff auf eine Seite entsprechend "Seitenfehler" (engl. "page fault").
 - Adressen des virtuellen Speichers heissen "virtuelle" Adressen und müssen für den tatsächlichen Zugriff in eine "physikalische Adresse" übersetzt werden:
 - => Dieser Prozess heisst: Adressabbildung bzw. Adressübersetzung (engl. "paging").



- "Paging" und "Segmentierung"
 - a) "Segmentierung"
 - Es werden Blöcke variabler Länge im Arbeitsspeicher genutzt;
 diese Blöcke heissen "Segmente".
 - Die virtuelle Adresse setzt sich aus einer virtuellen Segment-Nummer und einem Segment-Offset zusammen.
 - => Bei der Abbildung auf die physikalische Adresse müssen Segmentnummer und Segment-Offset übersetzt / berücksichtigt werden, da das Offset unterschiedlich gross sein kann und die Grenzen überprüft werden müssen.

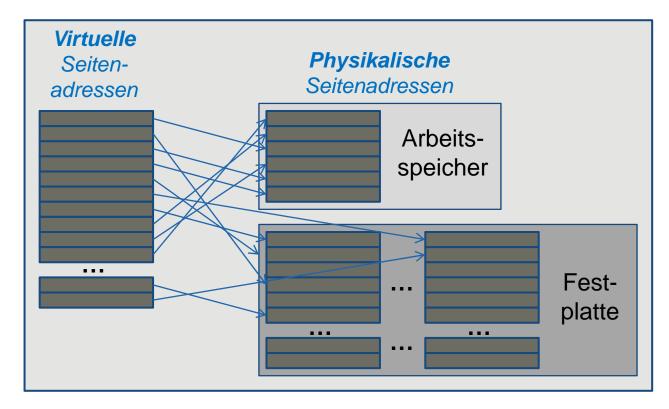


- "Paging" und "Segmentierung"
 - b) "Paging"
 - Es werden Blöcke fester Länge im Arbeitsspeicher genutzt;
 diese Blöcke heissen "(Page) Frames".
 - Die virtuelle Adresse setzt sich aus einer virtuellen Seitenadresse und einem Seiten-Offset zusammen.
 - => Bei der Abbildung auf die physikalische Adresse muss nur die Seitenadresse übersetzt werden, da das Seiten-Offset immer gleich gross ist.
 - Eine "Fragmentierung" des Speichers ist ausgeschlossen.
 - => Heute fast ausschliesslich Nutzung von "Paging".



Caches – Virtueller Speicher

Schema der Adressabbildung ("Paging")





Caches – Virtueller Speicher

"Reallocation":

Ein Programm (Prozess) muss nicht mehr fortlaufend im *Arbeits-speicher* (physikalisch) stehen, es muss nur über (auf) ausreichend viele *Seiten* im *Arbeitsspeicher* verfügen (zugreifen können), die im *virtuellen Speicher* fortlaufend als ein Block "*geladen*" werden.

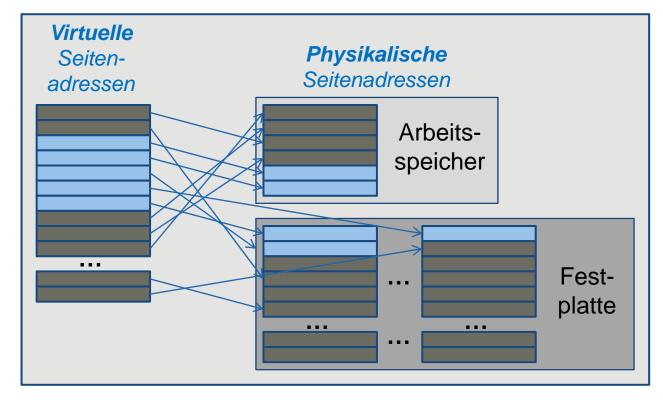
=> Laden eines Programms in jeden beliebigen Teil des Arbeitsspeichers.

(Für den Programmierer transparent)



Caches – Virtueller Speicher

Beispiel zu Reallocation





- Beim Entwurf ist insbesondere zu berücksichtigen, dass ein Fehlzugriff (Seitenfehler) sehr hohe Kosten zur Folge hat ! (über 10⁶ Taktzyklen!)
 - Grosse Seiten, um die langen Zugriffszeiten für das (Nach-) **Laden** zu "*nutzen*" – nicht dass nach wenigen Zugriffen erneut geladen werden muss.
 - Assoziatives Konzept für das Laden und Suchen der Seiten, um die Seitenfehlerrate zu reduzieren (voll- oder zumindest sehr hoch assoziativ).
 - Steuerung (auch für Seitenfehler) kann mit Software realisiert werden (Zugriff auf Festplatte deutlich länger).
 - Nutzung von Rückschreibetechniken (Durchschreibetechniken wäre um Grössenordnungen zu langsam).



Caches – Virtueller Speicher

- "Seitentabelle" (engl. "Page table")
 - Wie kann bei einem vollständig assoziativen Platzieren eine Seite im virtuellen Speicher gefunden werden?
 - (die Seite kann an jeder Position stehen und eine sequentielle Suche ist sicherlich nicht effizient).
 - => In einer "Seitentabelle" (individuell für jeden Prozess) wird diese Zuordnung festgehalten.

Bei modernen Rechnern kann die **Seitentabelle** mehrstufig (bis zu vier Stufen) aufgebaut sein, um sehr effizient mit kleinen Tabellen auch sehr grosse virtuelle Speicher zu verwalten.



Caches – Virtueller Speicher

- "Seitentabelle" (engl. "Page table")
 - Die Seitentabelle selber ist auch im virtuellen Speicher abgelegt. Wie wird die nun gefunden?
 - => In einem ausgezeichneten Register, dem "Seitentabellenregister", wird festgehalten, wo für das gerade ausgeführte Programm (Prozess) sich die Seitentabelle im virtuellen Speicher befindet.

Als positiver "*Nebeneffekt*" kann so sehr einfach und effizient ein **laufendes** Programm unterbrochen werden:

=> Es müssen **nur** das **Seitentabellenregister**, der **Befehlszähler** und die weiteren Register abgespeichert werden (nicht die ganze Seitentabelle oder gar der ganze genutzte Arbeitsspeicher!). - 92 -



Caches - Virtueller Speicher

- "Translation Lookaside Buffer" (TLB)
 - Da auf die Seitentabellen recht häufig zugegriffen wird, sollte die dafür erforderliche Zugriffszeit so gering wie möglich sein!
 - => In einem speziellen Cache, dem "Translation Lookaside Buffer", kann die Zugriffzeit auf einen Prozessorzyklus im Idealfall reduziert werden!

Beim *Translation Lookaside Buffer* handelt es sich um einen "echten", in Hardware realisierten Cache.



- "Austauschspeicher" (engl. "swap space")
 - Für jedes Programm (Prozess) wird beim Start für alle erforderlichen Seiten des Programms entsprechender Platz auf der Festplatte reserviert, der als *Austauschspeicher* bezeichnet wird.



- Austausch von Seiten
 - Strategie für den Austausch von Seiten:
 - => Rückschreibetechnik mit Least recently used
 - Rückschreiben von Seiten ist effizienter als das einzelne Wörter.
 (Festplatte => Suchzeit ist sehr viel grösser als Übertragungszeit.)
 - Es wird nur zurückgeschrieben, wenn dirty bit gesetzt.



